

RAG 实验 I

系统开销与可扩展性实验

项目项	最终口径
项目	VPER — Verifiable Policy-Governed Educational RAG
Experiment I 目标	评估完整系统开销，并验证资源库规模 N 与重排序截断 K 增长时的可扩展性
最终实验结构	I-Core（完整在线链路）+ Stage B（CP-ABE-aligned N/K scalability）
正式状态	paper_ready_i_core=true; paper_ready_i_scalability=true; paper_ready_i_final=true; paper_revision_ready=true

0. 执行摘要

I-Core 回答完整系统在真实在线交互路径中的时间开销由哪些部分构成；Stage B 则在 CP-ABE 对齐的本地环境中，把资源库规模 N 与重排序截断 K 作为受控变量，回答系统随着规模增大时的计算与存储扩展趋势。

最终结果表明：在 I-Core 的完整在线链路中，答案生成与语义增强占据绝大多数端到端时间，Merkle/proof verification 本身仅为毫秒级；在 Stage B 的大规模 CP-ABE 对齐检索中，随着 N 增大，在线主要瓶颈转移为 CP-ABE protected candidate recovery，而 verification 依然只占极小比例。离线构建则主要由 CP-ABE posting encryption 主导。K 增大时 CrossEncoder reranking 成本近似按比例增长，但由于固定大规模资源库下 CP-ABE recovery 已占主导，总检索侧延迟只温和增加。

维度	核心数字	解释
I-Core Te2e	7.197 s	Tgen 67.599%，Tsem 32.349%，verification 非主要瓶颈
Benign verification	Mean 1.212 ms; P50 1.091 ms; P95 2.893 ms	30,000 次重复，支持“毫秒级”而非“始终亚毫秒”
Repository N	164 → 2624（16×）	Tidx 5.772 → 73.174 min; retrieval-side 1.255 → 11.003 s
CP-ABE recovery	0.776 → 10.377 s	N=2624 时约占 mean retrieval-side latency 的 94.3%
Verification at N=2624	14.102 ms	仅约占 0.128% mean retrieval-side latency
Reranking K	5 → 30（6×）	Trerank mean 119.270 → 746.091 ms（6.26×），R²=0.9943
Total storage	0.359 → 4.763 GiB	16× N 对应 13.27× storage；平滑单调增长

Experiment I 证明的不是“所有安全开销都很小”，而是：verification 本身很轻；真正需要在大规模部署中优化的是 CP-ABE protected candidate recovery 与离线 posting encryption。

文档结构

- 1. 实验依据与研究问题
- 2. 总体实验思路与分层设计
- 3. 指标体系与 measurement boundary
- 4. 实验数据、模型与运行环境
- 5. I-Core: 完整系统开销基线
- 6. 为什么需要补充 Stage A / A2 / B
- 7. Stage A 与 Stage A2: CP-ABE 可行性和协议冻结
- 8. Stage B: 正式 Repository-N 与 Rerank-K 可扩展性实验
- 9. Stage B 正式结果
- 10. 结果分析: 逐项回答实验指导问题
- 11. 统计、审计与冻结策略
- 12. 实验边界、限制与不可过度声称之处
- 13. 论文表格/图片/正文的最终映射
- 14. 复现路径与正式结果文件
- 15. 最终结论

1. 实验依据与研究问题

1.1 实验指导要求

最新版实验指导要求验证框架在加入策略保护、可验证检索、语义重排、受控生成与日志治理之后，整体运行代价是否仍处于可接受范围，并考察随数据规模或参数变化的扩展趋势。指导要求至少分解 Tidx、Tret、Tver、Tsem、Tgen，并定义 $Te2e = Tret + Tver + Tsem + Tgen$ 与 $VO = Tver / Te2e$ ；可扩展性至少考察资源总量 N 与 reranking cutoff K 两个维度，并在条件允许时补充存储开销。

因此，Experiment I 必须同时回答“完整系统慢在哪里”和“规模增大以后哪个组件成为瓶颈”这两个问题；只做当前 164 文档资源库的单点延迟，或者只做 posting-list 大小变化，都不足以完整对应实验指导中的 $Tidx(N) / Te2e(N) / Te2e(K)$ 逻辑。

1.2 原论文口径

原论文同样把离线索引构建、受保护检索、proof verification、语义改写/重排与答案生成作为系统开销分解，并提出用 repository size N 与 reranking cutoff K 观察 scalability。Table VII 用于总结系统开销，Fig. 4 用于呈现 repository size 或 reranking depth 的趋势。

方法层面，原论文的教育资源首先通过策略控制：文档正文由对称密钥保护，密钥受 CP-ABE 策略保护；同时 encrypted posting entry 抽象表示为 $ABE.Enc(PK_{ABE}, Policy_i, id_i || aux_i)$ ，因此最终实验必须对“CP-ABE 是否只是论文公式、还是实际 prototype 能跑”给出明确实现说明。

1.3 本实验最终研究问题

1. 完整在线交互路径中，Tret、Tver、Tsem、Tgen 分别占多少时间？生成是否为主要瓶颈？
2. verification 的真实边际开销是多少？能否把 Proposed 与 w/o Verification 两次独立 API 运行的差值直接解释为验证开销？
3. 短时 verification 是否稳定？在大量 benign repetitions 下 Mean/P50/P95 是多少？
4. posting-list 增大时，verification latency 与 response size 如何变化？
5. 资源库 N 从 164 扩展到 2624 后，离线索引构建、CP-ABE 解密、verification、语义处理和存储如何扩展？
6. 固定大规模资源库下，仅改变 reranking cutoff K=5/10/20/30 时，CrossEncoder reranking 的成本如何增长？
7. 最终哪些结果适合写入 Table VII、Fig. 4、补充图，以及哪些结果必须明确为“不同环境、不可做绝对横向比较”？

2. 总体实验思路与分层设计




图 1 Experiment I 的最终分层实验逻辑。I-Core 负责完整在线开销，Stage B 负责 CP-ABE 对齐的规模扩展，二者通过 Stage A/A2 的门控与协议冻结衔接。

2.1 为什么不把所有内容做成一个实验

完整在线链路包含远程 LLM/API、网络、query rewriting、local reranking 与 verification；若直接在不同 N 上重复完整 LLM 端到端请求，会把远程生成波动混入 N/K 的本地 scalability，从而无法判断“repository 变大”究竟影响了哪一项。因此最终方案采用“分层测量”：I-Core 保留真实完整系统体验，Stage B 则隔离 local/cryptographic scalability，不调用最终 LLM。

Core = Windows + 完整在线路径 + 实际 generation/API；
Stage B = WSL + CP-ABE-aligned + 本地/检索侧可扩展性 + final LLM calls=0。
两者共同构成 Experiment I，但绝对 latency 不直接横向比较。

2.2 最终实验层级

层级	核心目标	主要内容	环境/性质
I-Core	完整系统开销与 verification 边际开销	Tret/Tver/Tsem/Tgen/Te2e/VO；30k verification；posting-list scaling	Windows；原 prototype
Stage A	CP-ABE runtime 与 Merkle 兼容性门控	Setup/KeyGen/Enc/Dec；wrong attrs；serialization；Merkle mutation；K 池扫描	WSL；planning-only
Stage A2	解决 arbitrary-byte posting contract，冻结 Stage B 协议	HybridABEnc decision；8 workers；N/K 固定；repeat 固定	WSL；planning-only
Stage B	正式 N/K scalability 与 storage	15 builds；900 Repository-N；1020 K-scale	WSL；正式论文结果
Paper Revision	只读 raw，修正统计表达与最终图表	n=3 不报 P95；Tabe_dec 语义审计；Fig.4/5/S1	不重跑实验

3. 指标体系与 Measurement Boundary

3.1 I-Core 论文指标

指标	定义	最终使用注意
Tidx	离线索引构建/检索准备时间	离线，不计入在线 Te2e
Tret	受保护检索时间	I-Core 原 prototype 的 retrieval path
Tver	proof / commitment verification 时间	短时组件，需独立微基准
Tsem	query rewriting + semantic reranking	I-Core 包括远程改写与本地语义处理
Tgen	答案生成时间	远程 LLM；I-Core 中通常为最大项
Te2e	Tret + Tver + Tsem + Tgen	在线端到端总延迟
VO	Tver / Te2e	最终使用 per-observation ratio 的均值，不直接用 aggregate mean 相除

3.2 Stage B 本地分解

指标	Stage B 定义	解释
Tret_core	protected lookup / serialized candidate return	不包含 CP-ABE decrypt
Tabc_dec	对 retrieved postings 的 CP-ABE/hybrid 恢复与解密	Stage B 中必须单列；大 N 下成为主要在线成本
Tver	Merkle/proof verification	与 G 的 integrity 逻辑一致，但 Stage B 使用 CP-ABE hybrid ciphertext
Tdense	本地 dense candidate processing	固定 dense_candidate_depth=30
Trerank	CrossEncoder reranking	K-scale 的直接受控变量
Tsem_local	Tdense + Trerank	Stage B 不含 remote rewrite
Retrieval-side total	Tret_core + Tabc_dec + Tver + Tsem_local	不是 full Te2e；不含 final LLM

3.3 存储指标

Stage B 将存储进一步细分为 encrypted document body (Sdoc)、CP-ABE-protected DEK metadata (Sdek)、protected searchable index (Sidx)、其中的 ABE postings (Sabe_posting)、verification/proof metadata (Sproof)、其他 metadata (Smetadata) 与 total artifact (Stotal)。最终图注必须明确：ABE postings ⊂ protected index ⊂ total artifact，它们并不是三个互斥存储组件。

4. 数据、模型与运行环境

4.1 基础资源库与查询

基础资源库为前面 C/G/H 已冻结的 MIT 6.5830 教育 RAG 数据，当前 repository 含 164 documents；正式查询集为 60 条，覆盖 QAssess、QConcept、Qlookup、Qmanage 四类。Stage B 的 repository expansion 使用 performance-only replication：副本文本与 policy 语义保持不变，但 doc_id/doc_tag/crypto randomness 均

唯一；这些副本只用于 computational/storage scalability，不用于 Recall、nDCG、answer quality 或 retrieval accuracy。

4.2 Retrieval 模型与固定参数

配置	最终冻结值
Dense model	bge-small-en-v1.5
CrossEncoder	cross-encoder-ms-marco-MiniLM-L-6-v2
Repository-N dense_candidate_depth	30
Repository-N rerank_cutoff	20
final_top_k	5
K-scale fixed repository	N=2624; canonical N2624_R01
K-scale K values	5 / 10 / 20 / 30
K-scale eligible queries	51: QAssess 15, QConcept 11, Qlookup 12, Qmanage 13

4.3 Stage B 密码学运行环境

项目	环境
OS	Ubuntu 26.04 LTS (WSL2)
Kernel	6.18.33.2
Python	3.14.4
Charm-Crypto	0.63
Pairing library	Stanford PBC 1.0.0
CP-ABE scheme	CPabe_BSW07
Group	BN254
Arbitrary payload implementation	Charm HybridABEnc (标准 hybrid instantiation)
CP-ABE workers	8
Stage B API calls	0

5. I-Core: 完整系统开销基线

5.1 设计目的

I-Core 的目的不是做大规模 expansion，而是保留“真实用户请求路径”的端到端开销。它测量 Proposed Framework、Secure Retrieval Baseline 与 Ours w/o Verification 等设置的在线各阶段时间，其中 Proposed 的完整链路包含远程生成，因此能够回答“整体响应慢在哪里”。

5.2 Proposed Framework 的完整在线分解

指标	Proposed Framework
Tret	2.477 ms
Tver	1.292 ms
Tsem	2328.184 ms
Tgen	4865.174 ms
Te2e	7197.126 ms
VO	约 0.0192%




图 2 I-Core 完整在线链路的平均延迟分解。生成与语义增强构成绝大多数端到端延迟。（仅示意，不放入论文中）

从 mean Te2e 看，Tgen 占 67.599%，Tsem 占 32.349%；Tret 与 Tver 合计只占极小比例，系统瓶颈主要来自 remote answer generation 和 semantic processing，而不是 proof verification。

5.3 为什么不能直接用 Proposed – w/o Verification 的 80.392 ms

Proposed 与 w/o Verification 是独立端到端请求，二者都包含 API、网络、query rewriting、reranking 与 generation 的自然波动。因此观察到的约 80.392 ms 差值不是“验证模块的因果开销”。最终采用 component-wise paired decomposition：在同一份 Proposed frozen measurement 上，只移除其 Tver 组件，60/60 paired units 全部通过 arithmetic/source consistency。

最终 verification 边际开销

Mean marginal verification overhead = 1.292 ms；mean verification-overhead fraction $\approx$ 0.0192%。这比直接拿两次独立端到端运行相减更符合因果口径。

5.4 Benign verification 微基准

统计量	值
N	30,000
Mean	1.211927 ms
P50	1.091100 ms
P95	2.893205 ms
Min	0.239600 ms
Max	11.268800 ms

这一微基准的意义是把“短时 proof verification”从远程 API 噪声中独立出来。结果支持“典型 verification 为毫秒级”的表述，但不支持“always sub-millisecond”。这种克制表述更适合论文。

5.5 Posting-list / response-size 扩展

Posting-list size	Mean verify (ms)	P50 (ms)	P95 (ms)	Response (KiB)
1	0.0484	0.0408	0.0845	3.085
5	0.1128	0.1015	0.1783	6.925
10	0.1825	0.1736	0.2380	11.756
20	0.3365	0.3239	0.4191	21.351
40	0.6649	0.6360	0.8040	40.701




图 3 I-Core 补充的 posting-list verification/response-size scalability。该图在最终论文中更适合作为 Supplementary Fig. S1，而不是 repository-size Fig. 4。

posting-list 从 1 增至 40 时，Mean verification latency 从 0.048 ms 增至 0.665 ms，serialized response 从约 3.085 KiB 增至 40.701 KiB。两者均平滑增长，但这只是“单个 proof/response 负载规模”的扩展，不等价于 repository N 的扩展，因此最终将其降级为 supplementary verification-response scalability。

5.6 I-Core 离线 Tidx 补测

在原 164-document repository 上，I-Core 还单独完成了 full offline retrieval-preparation benchmark。5 次正式 build 的 mean Tidx = 24.299 s, P50 = 24.551 s, P95 = 25.783 s。这个 Tidx 属于原 Windows prototype 的离线准备成本，不计入 online Te2e。后续 Stage B 使用 CP-ABE-aligned WSL 环境后，离线 Tidx 的绝对值发生数量级变化，因此两者不可直接用“快了/慢了多少”作绝对比较。

6. 为什么还需要 Stage A / A2 / B

6.1 Repository-size gap

I-Core 最初的 scalability 只改变 posting-list size，并未真正改变 repository resource count N ；而实验指导和原论文明确把 N 定义为 repository resources。因此若不补充 $N=164/328/656/1312/2624$ 的 performance-only repository workload，Fig. 4 的“repository-size scalability”就没有直接实验支撑。

6.2 CP-ABE method alignment gap

原论文方法中，文档正文通过 symmetric encryption 保护、DEK 受 CP-ABE 策略保护，同时 encrypted posting entry 抽象写为 $\text{ABE.Enc}(\text{PK}, \text{Policy}, \text{id} || \text{aux})$ 。旧 G/I prototype 主要使用 policy-bound AES-GCM protected entry，因此 integrity 结果可继续作为 integrity prototype 结果，但不能把它描述为已经验证了 CP-ABE confidentiality / authorization。为解决这一点，Stage A/A2 专门建立 CP-ABE runtime 与 implementation clarification。

7. Stage A 与 Stage A2: CP-ABE 可行性与协议冻结

7.1 Stage A: 先证明 runtime、policy 与 Merkle 能兼容

- 在独立 WSL 环境安装并验证 Charm-Crypto 0.63、PBC 1.0.0、CPabe_BSW07、BN254；不污染 Windows .venv。
- Setup、KeyGen、authorized decrypt PASS；wrong role/course/stage/clearance 均 decrypt FAIL。
- Document body 的 symmetric encryption + CP-ABE-protected DEK smoke PASS。
- CP-ABE ciphertext objectToBytes $\rightarrow$ bytesToObject $\rightarrow$ objectToBytes 字节稳定；Merkle valid PASS，Forge/Drop/Pollute/Reorder 均按预期 FAIL。
- 候选池扫描发现 $N=164$ 时只有 11/60 queries 拥有 ≥ 30 policy-authorized candidates，因此不能直接用全部 60 queries 做 $K=30$ 。

7.2 Direct arbitrary bytes 为什么失败

CPabe_BSW07 的原生消息空间是 GT；在 BN254/MNT224/SS512 下，Charm 的 PairingGroup.encode/decode 并未提供可用的 arbitrary bytes $\rightarrow$ group element 路径。真实 posting payload 为约 218–286 B；若手工 chunking 再分别做 CP-ABE，会变成论文未定义的新密码构造，因此没有采用。

7.3 Stage A2: 采用标准 HybridABEnc

Stage A2 最终作出 Decision B：论文中的 $\text{ABE.Enc}/\text{ABE.Dec}$ 保持抽象 CP-ABE 接口，prototype 使用 Charm 官方 HybridABEnc(CPabe_BSW07, BN254) 作为 arbitrary-length posting payload 的标准 hybrid instantiation。CP-ABE 负责按 posting policy 保护 fresh session secret，对称层只负责承载 arbitrary-length

serialized payload。Unauthorized attributes 仍无法恢复 session secret 或 payload，因此 policy-satisfaction security semantics 不变；论文只需增加 implementation clarification，不需要改公式。

论文中不要写“Route B”。只写：the prototype instantiates the abstract CP-ABE interface using Charm’s standard hybrid construction；不得声称 direct arbitrary-byte GT encryption。

7.4 Planning-only 性能与 8 workers 选择

Workers	Throughput	Enc mean	Errors
1 worker	28.681 entries/s	32.497 ms	0
2 workers	58.134 entries/s	31.953 ms	0
4 workers	116.722 entries/s	31.789 ms	0
8 workers	216.137 entries/s	32.899 ms	0

这些数值是 PLANNING_ONLY_NOT_PAPER_RESULT，仅用于决定 Stage B 是否可运行以及固定 worker_count=8；不进入正式论文结果表。

7.5 K 候选池如何从 11 条扩展到 51 条

Performance N	Queries with ≥ 30 authorized candidates	Category composition
164	11/60	Assess 7; Concept 0; Lookup 4; Manage 0
328	20/60	Assess 11; Concept 0; Lookup 6; Manage 3
656	29/60	Assess 13; Concept 2; Lookup 9; Manage 5
1312	47/60	Assess 15; Concept 8; Lookup 12; Manage 12
2624	51/60	Assess 15; Concept 11; Lookup 12; Manage 13

最终 K-scale 固定 N=2624，选择所有预先满足 ≥ 30 policy-authorized candidates 的 51 条 queries，而不是根据未来 latency 结果挑样本。dense_candidate_depth=30 已足够覆盖这 51 条 queries，K=5/10/20/30 时只改变 rerank_cutoff，candidate universe 保持一致。

8. Stage B: 正式 Repository-N 与 Rerank-K 实验设计

8.1 Repository-N workload

正式 N 取 164、328、656、1312、2624。每个 N 做 3 次 formal build；只在 N=164 做 1 次非正式 warm-up。Repository-N online 对全部 60 frozen queries 做 3 repeats，因此每个 N 有 180 observations，五档共 900 observations。

- 所有 N 使用同一 query set、policy、trusted role/stage/course/sensitivity、dense model、CrossEncoder、dense depth=30、rerank cutoff=20、final top-k=5。
- 唯一 workload-scale 自变量为 repository_N。

- performance replicas 生成唯一 doc_id/doc_tag/crypto randomness；禁止因为文本相同而被 embedding/CrossEncoder cache 或 dedup 跳过。
- 每个 formal build 完成后立即写 raw、validation、SHA 与 DONE.json；失败不得静默替换。

8.2 Rerank-K workload

K-scale 固定 canonical N2624_R01 repository、51 条 eligible queries、dense_candidate_depth=30、final_top_k=5，仅改变 rerank_cutoff=5/10/20/30。每个 query×K 做 5 repeats，因此 51×4×5=1020 formal observations。pairing audit 要求四个 K 的 candidate_pool_hash 完全一致，authorization mismatch 与 crypto-mode mismatch 均为 0。

8.3 正式执行规模

Workload	Formal observations	组成	Validation
Repository builds	15	5 N × 3 formal builds	PASS
Repository-N online	900	60 queries × 3 repeats × 5 N	PASS
Rerank-K	1020	51 queries × 4 K × 5 repeats	PASS

9. Stage B 正式结果

9.1 离线索引构建 Tidx(N)

N	Tidx Mean (min)	P50 (min)	CP-ABE posting enc Mean (min)	Posting enc / Tidx
164	5.772	5.766	5.062	87.70%
328	10.863	10.870	9.708	89.37%
656	18.575	18.575	16.725	90.04%
1312	36.128	36.058	32.274	89.33%
2624	73.174	73.060	64.482	88.12%

N 从 164 增至 2624 (16×) 时，mean Tidx 从 5.772 min 增至 73.174 min (12.68×)，线性描述拟合 $R^2=0.9994$ ，因此可谨慎表述为“在测试范围内近似成比例/near-linear”，不应写成“严格线性”。CP-ABE posting encryption 占 mean Tidx 的 87.70%–90.04%，是主要离线构建成本。

9.2 Repository-N 在线检索侧延迟

N	Tabe_dec Mean (s)	Tver Mean (ms)	Tsem_local Mean (s)	Retrieval-side Mean (s)	P95 (s)
164	0.776	1.530	0.476	1.255	2.776
328	1.407	2.292	0.476	1.893	4.067
656	2.650	3.859	0.486	3.152	7.240
1312	5.367	7.627	0.573	5.969	14.720
2624	10.377	14.102	0.574	11.003	28.578




图 4 Scalability 主结果的 summary 重绘：（a）Repository size N 对 retrieval-side latency；（b）Reranking cutoff K 对 reranking latency

9.3 Tabe_dec 为什么随 N 大幅增长

paper-layer semantic audit 进一步检查了真实 pipeline: protected posting lookup → Merkle verification → 对全部 retrieved postings 尝试 CP-ABE decrypt → authorized candidates 去重 → dense top-30 → CrossEncoder → final top-5。也就是说 dense_candidate_depth=30 发生在 decrypt 之后，而不是之前。随着 N 扩大，平均 decrypt attempts 从 38.48 增至 615.73，因此 Tabe_dec 从 0.776 s 增至 10.377 s 是由真实 cryptographic workload 增长造成，不是 timer boundary 错误。

N	Tabe_dec share	Tsem_local share	Tver share	Tret_core share
164	61.8%	37.9%	0.122%	0.147%
328	74.3%	25.2%	0.121%	0.409%
656	84.1%	15.4%	0.122%	0.376%
1312	89.9%	9.6%	0.128%	0.369%
2624	94.3%	5.2%	0.128%	0.345%

9.4 Rerank-K 结果

K	n	Trerank Mean (ms)	P50	P95	Tsem_local Mean (ms)	Retrieval-side Mean (s)
5	255	119.270	118.371	218.115	155.860	12.288
10	255	234.050	194.731	438.605	270.215	12.421
20	255	535.793	712.551	885.157	573.243	12.719
30	255	746.091	796.778	1322.470	783.880	12.940

K 从 5 增至 30 (6×) 时，Trerank mean 从 119.270 ms 增至 746.091 ms (6.26×)，线性描述拟合 $R^2=0.9943$ ，说明 CrossEncoder reranking 在测试范围内近似按 K 成比例增长。与此同时 retrieval-side mean 仅从 12.288 s 增至 12.940 s (+5.31%)，因为固定 N=2624 时约 12.1 s 的 CP-ABE recovery 已占主导。

9.5 Storage scaling

N	ABE postings (GiB)	Protected index (GiB)	Proof metadata (MiB)	Total artifact (GiB)
164	0.246	0.289	67.10	0.359
328	0.496	0.581	67.10	0.653
656	0.994	1.165	67.10	1.240
1312	1.990	2.333	67.11	2.414
2624	3.984	4.669	67.14	4.763




图 5 Offline/storage summary: (a) mean index construction time; (b) storage scaling, 本图的 panel (a) 仅绘制 summary mean; 最终论文 Fig. 5 使用 3 个 raw points + mean ± sample SD。

Total artifact 从 0.359 GiB 增至 4.763 GiB，增长 13.27×；趋势平滑单调、近似成比例。Sproof 约维持在 67 MiB 左右，因此 total storage 并未严格按 16× 放大。最终 caption 必须明确 ABE postings 属于 protected index，而 protected index 又属于 total artifact。

9.6 正常 fail-closed observations

每个 N 的 180 observations 中均有 6 条 empty-authorized-candidate observations。审计确认它们固定来自 QC002、QC008，两条均为 QConcept、student、pre_class、restricted；每条 query × repeats 1–3，因此恰好 2×3=6。它们是 policy 正常 fail-closed，不是检索 bug，正式 raw 中保留而未删除。

10. 结果分析：逐项回答实验指导问题

实验指导问题	数据回答	论文解释
verification 是否是主要瓶颈？	不是。I-Core Tver mean=1.292 ms; 30k benign mean=1.212 ms; Stage B N=2624 时 Tver mean=14.102 ms, 仅约占 retrieval-side mean 的 0.128%。	可以写“Merkle/proof verification remains a minor component”，但不能扩大成“all security overhead is negligible”。
语义增强代价是否值得？	I-Core Tsem≈2.328 s，约占 Te2e 的 32.349%；Stage B local semantic processing 在 N 扩展时只从 0.476→0.574 s。	I-Core 中语义增强不是免费，但相比 generation 和大规模 CP-ABE recovery，具有清晰且可解释的成本边界。
生成是否为整体主要来源？	在 I-Core 是。Tgen≈4.865 s，占 Te2e 的 67.599%。	应解释为 remote LLM generation 是当前完整用户路径的主要延迟来源，而不是 security verification。

实验指导问题	数据回答	论文解释
随 N 增长是否可扩展？	Tidx 近似成比例增长；online retrieval-side 1.255→11.003 s。主要增长来自 Tabe_dec，而不是 Tver/Tsem_local。	系统能够扩展，但 CP-ABE protected candidate recovery 是大规模部署的优化重点。
随 K 增长是否可扩展？	Trerank mean 随 K 近似按比例增长；K 5→30 时 119→746 ms。	CrossEncoder cost 可预测；在 N=2624 下 total local latency 只增长 5.31%，因为 CP-ABE recovery 已主导。

10.1 最重要的机制性结论

从 I-Core 到 Stage B 的瓶颈迁移

小规模完整在线链路：瓶颈 = generation + semantic processing。大规模 CP-ABE-aligned local retrieval：瓶颈 = CP-ABE candidate recovery。两种结果并不矛盾，因为 measurement boundary 与 workload 不同。

这一“瓶颈迁移”比简单宣称“安全机制开销很小”更有论文价值。它揭示了可信教育 RAG 的工程优化方向：Merkle verification 已足够轻，而在受保护大规模资源库中，真正需要优化的是 expensive cryptographic recovery、候选裁剪时机、批处理或硬件加速。注意这些只是未来优化方向，本实验并未声称已经实现。

11. 统计、审计与冻结策略

11.1 为什么 build/storage 不在论文里报 P95

Stage B 每个 N 只有 3 次 formal build。机器 summary 曾自动计算 P95，但最终 paper-layer revision 明确移除了 n=3 的 P95 表达：论文侧只使用 Mean、P50、sample SD (ddof=1)、Min、Max；最终 Fig. 5(a) 用 3 个 raw points + mean ±1 sample SD。Repository-N online 每 N 有 180 observations，K-scale 每 K 有 255 observations，因此这些在线结果可以正式报告 P95。

11.2 Frozen raw 与 SHA

Frozen raw	Rows	SHA-256
repository_build_raw.csv	15	a7f9d141a7d59a6e31058a7b79b6f11f143b18d6c80b3de28957db4cefd63681
repository_online_raw.csv	900	ec99db7b2fae7fe8ccd44c8e09a997e4594a0cce6eb2ab20ca7a0fbc93c5c791
rerank_K_raw.csv	1020	7c9ffe6ef95aa6dd0c88e17a6eb05595a69e1d02d501cce0d0feda2cd21e0347

11.3 关键 validation gate

Gate	最终结果
Repository builds	15/15 formal PASS; 0 FAILED
Repository-N online	900/900 frozen; authorization mismatch=0
Rerank-K	1020/1020 frozen; candidate-pool hash mismatch=0; crypto mismatch=0

Gate	最终结果
CP-ABE policy	authorized PASS; wrong role/course/stage/clearance FAIL
Merkle compatibility	valid PASS; Forge/Drop/Pollute/Reorder FAIL as required
Latency identity/ Figure source arrays	mismatch=0
Preservation	G/H5 native/H6/I-Core/dataset/protocol/index/embeddings/models unchanged
API	new_api_calls_stageB=0

11.4 H5 junction preservation 特殊处理

H5 中两个 node_modules junction 指向外部 mutable Codex runtime。最初 strict-tree SHA 递归进入外部 target 后产生假阳性 mismatch。最终 preservation scope 改为 native_tree_excluding_external_reparse_targets: junction path/type/target metadata 仍记录，但不递归 hash 外部 target；H5 native mismatch=0，junction metadata mismatch=0。因此这不是“放宽审计”，而是修正 artifact boundary。

12. 实验边界、限制

限制/边界	必须怎样写
Performance-only replication	N=328...2624 的副本只用于 computational/storage scaling，不用于 retrieval quality 或 generalization。
跨环境边界	I-Core 为 Windows full-path；Stage B 为 WSL CP-ABE-aligned local benchmark。不得用绝对 latency 直接比较谁快多少。
No final LLM in Stage B	Stage B 的 N/K 是 retrieval-side/local scalability，不是 measured full Te2e(N/K)。
K query subset	K-scale 使用 51/60 queries，因为只有这 51 条在 N=2624 下有 ≥30 policy-authorized candidates。
n=3 offline builds	离线 build/storage 只做 3 formal runs/N，因此论文不使用 P95 inference。
CP-ABE claim boundary	实验验证 implementation correctness、policy-satisfaction behavior、performance 与 Merkle compatibility；不能说“benchmark 证明了 CP-ABE 密码学安全”。
G 与 Stage B 边界	Frozen G 是 integrity/attack formal evaluation；Stage B 证明 CP-ABE hybrid 与同一 commitment design 可兼容，但不能说 G 已完整用 CP-ABE 重跑。

13. 论文表格、图片与正文的最终映射


13.1 Table VII: 只放 I-Core canonical full-system overhead

原论文 Table VII 用于 SYSTEM OVERHEAD，因此最终应以 I-Core 的 164-doc canonical full online measurement 为主。Tidx 作为 offline retrieval preparation 单独列出，Te2e 仍只等于 Tret+Tver+Tsem+Tgen；0.000 表示对应模块“by design absent”，不是 unmeasured；VO 应说明为 per-observation Tver/Te2e 的均值。

Setting	Tidx (ms)	Tret	Tver	Tsem	Tgen	Te2e	VO
Current repository (164 docs)	24,298.594	2.477	1.292	2,328.184	4,865.174	7,197.126	0.0192%


13.2 Fig. 4: 正文主 scalability 图

最终 Fig. 4 应横向 1×2: panel (a) = repository size N 对 retrieval-side latency (Mean/P50/P95); panel (b) = reranking cutoff K 对 Trerank latency (Mean/P50/P95)。这与原论文 caption “with respect to repository size or reranking depth” 直接对应。



13.3 Fig. 5 / Supplement: offline + storage

Fig. 5(a) 用 $N \rightarrow \text{Tidx}$, 显示 3 个 formal raw points + mean ± 1 sample SD; Fig. 5(b) 用 $N \rightarrow \text{storage}$, 显示 Total artifact / Protected index / ABE postings。旧 posting-list verification/response-size 图改为 Fig. S1 supplementary。






Fig. S1 supplementary

13.4 可直接写进论文的中文分析段落

在系统开销实验中，我们首先在线交互路径上分解受保护检索、proof verification、语义增强与答案生成的时间成本。对于完整框架，Tret、Tver、Tsem 和 Tgen 的平均延迟分别为 2.477 ms、1.292 ms、2328.184 ms 和 4865.174 ms，对应 7197.126 ms 的平均在线端到端延迟。生成阶段约占 67.599%，语义增强约占 32.349%，表明在当前资源库规模下，主要在线成本来自远程生成与语义处理，而非 proof verification。30,000 次 benign verification 重复测量进一步得到 1.212 ms 的平均验证时延、1.091 ms 的中位数和 2.893 ms 的 P95，说明 verification 具有稳定的毫秒级开销。

为考察系统扩展性，我们在 CP-ABE 对齐的本地环境中将 performance-only repository 从 164 扩展至 2624 个资源，并固定查询、策略、dense candidate depth、reranking cutoff 和模型配置。离线索引构建时间从 5.772 min 增至 73.174 min，且 CP-ABE posting encryption 始终占平均构建时间的 87.70%–90.04%，成为主要离线成本。在线检索侧平均延迟由 1.255 s 增至 11.003 s，其中 CP-ABE candidate recovery 由 0.776 s 增至 10.377 s；在 N=2624 时其占比约为 94.3%，而 Merkle verification 仅约占 0.128%。这说明大规模受保护资源库中的主要瓶颈并非 verification，而是 policy-protected candidate recovery。

在固定 N=2624 的资源库上，将 reranking cutoff 从 5 增至 30 时，CrossEncoder reranking 的平均时延由 119.270 ms 增至 746.091 ms，呈近似成比例增长；但总 retrieval-side latency 仅增加约 5.31%，这是因为固定大规模资源库下 CP-ABE recovery 已经占据主要成本。总体而言，实验表明 verification 本身保持较低开销，而 CP-ABE posting encryption 与 candidate recovery 是进一步扩大可信教育 RAG 部署规模时更值得优化的工程环节。

14. 复现路径与正式结果文件

以下路径是当前项目中 Experiment I 的关键正式目录。本文档只做说明，不对这些 frozen artifacts 进行任何修改。

Artifact	Path
ProjectRoot	D:\Project\ProjectRAG\RAG
I-Core frozen	D:\Project\ProjectRAG\RAG\expl_overhead_scalability
Stage B root	D:\Project\ProjectRAG\RAG\expl_scalability_final
Stage A readiness	...\expl_scalability_final\stageA_readiness
Stage A2	...\expl_scalability_final\stageA2
Stage B final report	...\expl_scalability_final\stageB_results\stageB_final_report.md
Paper revision root	...\expl_scalability_final\stageB_paper_revision_final
Authoritative manifest	...\stageB_paper_revision_final\final_report\experiment_I_paper_ready_manifest.json
Final Fig.4	...\stageB_paper_revision_final\figures\fig4_scalability_final.pdf
Final Fig.5	...\stageB_paper_revision_final\figures\fig5_offline_scalability_final.pdf
Final Fig.S1	...\stageB_paper_revision_final\figures\figS1_verification_response_scalability.pdf
Final Table VII	...\stageB_paper_revision_final\tables\table_vii_canonical_system_overhead.md

14.1 本说明文档的依据

来源	用于本说明的内容
实验指导	最新版 I 部分：系统开销指标、N/K 可扩展性、存储建议、重复测量与最终交付物要求
Educational RAG(4).pdf	原论文方法与 Experiment I 口径：Tidx/Tret/Tver/Tsem/Tgen、Te2e、VO、N/K、Table VII、Fig.4，以及 CP-ABE protected posting 抽象接口
VPER Experiment I I-Core report	完整在线链路、paired verification、30k microbenchmark、posting-list scalability、原 Tidx 补测
Stage B frozen summaries / final audit	CP-ABE-aligned N/K formal results、storage、pairing、preservation、paper-layer semantic audit

15. 最终结论

Experiment I 已形成一条从“完整系统开销”到“规模扩展瓶颈”的完整证据链。I-Core 证明在 164-document canonical system 下，生成与语义增强是端到端延迟的主要来源，proof verification 本身仅为毫秒级；paired decomposition 与 30,000 次 benign microbenchmark 避免了把远程 API 波动错误归因于 verification。

Stage A/A2 解决了论文 CP-ABE method 与旧 prototype 之间的实现边界：最终采用 Charm HybridABEnc + CPabe_BSW07 + BN254 作为抽象 ABE.Enc/ABE.Dec 的标准 hybrid instantiation，并通过 policy-satisfaction、serialization 与 Merkle compatibility 审计。Stage B 在这一实现上完成 15 个 formal builds、900 个

Repository-N observations 与 1020 个 K-scale observations, 所有 pairing、authorization、crypto mode、raw freezing 与 preservation gate 均 PASS。

最终数据说明：随着 repository N 扩大，offline Tidx 和 storage 平滑增长，而 online local bottleneck 逐步集中到 CP-ABE protected candidate recovery；verification 始终保持极小比例。随着 K 增大，CrossEncoder reranking 成本按预期增长，但在大规模 CP-ABE workload 下不会成为总检索侧延迟的主导项。该结论既满足实验指导的可扩展性要求，也为论文 Discussion 提供了明确的工程优化方向。

最终状态

paper_ready_i_core=true; paper_ready_i_scalability=true; paper_ready_i_final=true; paper_revision_ready=true。
Experiment I 不再重跑，后续只允许从 frozen raw 派生排版级表格、图和文字。