

VPER Experiment I

系统开销与可扩展性实验报告

项目	正式状态
实验模块	Experiment I — System Overhead & Scalability
知识库规模	164 documents
在线端到端结果	PASS
Benign verification microbenchmark	PASS, N=30,000
Posting-list scalability	PASS, 5 scales
Offline Tidx benchmark	PASS, 5 formal repeats
API 增量调用	0
最终状态	paper_ready_i=true

1. 实验概述

Experiment I 的目标是评估在策略保护、可验证检索、语义增强、受控生成和治理机制加入后，系统的离线构建成本、在线端到端延迟、验证开销以及随 `posting-list` 规模增长时的可扩展性。根据您在群里要求，本实验特别强调 `benign verification` 的重复测量（Mean/P50/P95）以及 `posting-list / response-size scalability`。

最终结果表明：完整框架的在线平均端到端延迟为 7197.126 ms，其中 `generation` 占 67.599%，`semantic enhancement` 占 32.349%，`proof verification` 仅占约 0.018% 的 `observed latency`；在更严格的 `component-wise paired causal decomposition` 中，`verification` 的平均边际开销为 1.291768 ms，平均 VO 为 0.019201%。因此，当前系统的主要部署瓶颈来自远程生成和语义增强，而不是 `proof verification`。

离线 Tidx 采用独立临时目录进行 1 次 `warm-up` + 5 次正式构建，完整覆盖冻结输入校验、`protected index`、`AES-GCM`、`Merkle metadata`、`metadata serialization`、`dense document embedding` 预计算及本地模型加载。平均 Tidx 为 24.299 s，且未修改正式索引、数据集、G/H5 或既有 I raw。

说明：本报告严格区分“observed independent end-to-end latency”和“component-wise paired causal verification overhead”。独立运行的 Proposed-w/o Verification 差值 80.392 ms 不被解释为 verification 的因果成本。

2. 思路

2.1 实验目标

- 测量离线索引构建成本 Tidx，确认 protected retrieval 所需的离线准备成本。
- 分解在线端到端延迟为 Tret、Tver、Tsem、Tgen，并计算 Te2e。
- 对 benign proof verification 进行高重复 microbenchmark，报告 Mean、P50、P95、Min、Max。
- 严格估计 Verification 的边际开销，避免把独立 API/network 波动误判为 verification cost。
- 控制 posting-list size，测量 verification latency 与 serialized response size 的增长趋势。
- 判断当前系统真正的 latency bottleneck，并评估 verification 是否构成实际部署瓶颈。

2.2 时间指标定义

指标	定义	是否计入在线 Te2e
Tidx	Offline index construction / retrieval preparation time	否
Tret	Protected/encrypted retrieval 到候选返回完成的时间	是
Tver	Proof verification 路径的时间	是
Tsem	Query rewriting + semantic retrieval/reranking 时间	是
Tgen	Final answer generation 时间	是
Te2e	在线端到端延迟	—
VO	Verification overhead fraction = Tver / Te2e	—

$$\text{Te2e} = \text{Tret} + \text{Tver} + \text{Tsem} + \text{Tgen}$$

$$\text{VO} = \text{Tver} / \text{Te2e}$$

说明：Tidx 是离线构建成本，不加入在线 Te2e。此次 Tidx 的 scope 是 full offline retrieval preparation，因此不能把 24.299 s 解释为“仅 AES/Merkle 建索引耗时”。

2.3 实验总体思路

Experiment I 采用“冻结正式 raw → 只读审计 → 派生统计 → 缺失项隔离补测 → preservation audit”的思路。已有 latency_raw.jsonl、scalability_raw.csv 以及 G 中 30,000 次 benign verification measurement 优先复用，不为重新出表而重跑昂贵 API。对于 w/o Verification 的因果比较，不再直接使用两个独立 end-to-end run 的差值，而是基于同一条 Proposed 实测分量进行 component-wise paired causal decomposition，仅移除实测 Tver。Tidx 缺失后，再通过独立临时目录完成纯本地、零 API 的隔离构建 benchmark。

3. 实验对象、冻结资产与前置可信性检查

项目	内容
ProjectRoot	D:\Project\ProjectRAG\RAG
Processed data	D:\Project\ProjectRAG\RAG\data\processed
G frozen	D:\Project\ProjectRAG\RAG\expG_verify
H5 frozen	D:\Project\ProjectRAG\RAG\expH_answer_quality_teacher_evidence_alignment_20260818
I	D:\Project\ProjectRAG\RAG\expI_overhead_scalability
Dense model	bge-small-en-v1.5（本地）
Reranker	cross-encoder-ms-marco-MiniLM-L-6-v2（本地）

I 的正式运行建立在 G/H5 已冻结的可信边界上。

说明：Query rewrite 只允许产生 keywords、material_types、candidate_preferences；role、stage、course membership、max sensitivity 来自 trusted client attributes。I 不重新运行 G，而是只读确认这些前置 gate。

4. 具体实验步骤

Step 1: 只读审计现有 I。检查 latency_raw.jsonl、scalability_raw.csv、benign verification raw、旧 summary/report 与 SHA-256；确认已有 raw 可复用，不盲目重跑。

Step 2: 端到端 latency decomposition。对 Secure Retrieval Baseline、Ours w/o Verification、Proposed Framework 使用相同 benign query set，统计 Tret/Tver/Tsem/Tgen/Te2e。现有正式 raw 为 20 queries × 3 methods × 3 repeats = 180 rows。

Step 3: 修复 Proposed vs w/o Verification 的因果解释。发现独立 run 中 3 对 protected response mismatch 与 2 对 candidate-count mismatch，因此不把 80.392 ms raw Te2e difference 当作 verification

cost。改用同一 Proposed row 的 component-wise paired decomposition: $T_{shared}=T_{ret}+T_{sem}+T_{gen}$; w/o Verification counterfactual= T_{shared} ; Proposed= $T_{shared}+T_{ver}$ 。

Step 4: Benign verification microbenchmark。复用 30,000 次正常、可验证通过的 verification-only measurement, 统计 Mean/P50/P95/Min/Max, 避免只报告单次或“always sub-ms”。

Step 5: Posting-list scalability。固定 scale = 1/5/10/20/40, 复用 1000-row scalability raw, 统计 verification Mean/P50/P95 和 serialized response size。

Step 6: Tidx 隔离补测。在独立临时 benchmark 目录中完成 full offline retrieval preparation; 1 次 warm-up + 5 次正式 build; 不修改正式 index/embedding/dataset, 不下载模型, 不调用 API。

Step 7: Validation & preservation。再次校验 G/H5/dataset/protocol/原 I raw 与正式 index 未修改, API 增量调用为 0, 最终 paper_ready_i=true。

5. 实验结果

5.1 Observed Independent End-to-End Latency

Method	Tret (ms)	Tver (ms)	Tsem (ms)	Tgen (ms)	Te2e (ms)
Secure Retrieval Baseline	2.433	0.971	0.000	4784.532	4787.936
Ours w/o Verification	2.639	0.000	2265.729	4848.366	7116.734
Proposed Framework	2.477	1.292	2328.184	4865.174	7197.126

Table I-A. Observed independent end-to-end latency breakdown

独立运行结果显示, Secure Retrieval Baseline 的平均 Te2e 为 4787.936 ms; Ours w/o Verification 为 7116.734 ms; Proposed Framework 为 7197.126 ms。Proposed 相比 w/o Verification 的独立运行差值为 80.391768 ms (1.129616%), 但该差值包含 API、网络、rewrite、reranking 与 generation 的运行间波动, 因此不能解释为 verification 的因果开销。

5.2 Component-wise Paired Causal Verification Overhead

指标	结果
N pairs	60
Pair valid / mismatch	60 / 0
Verification Mean	1.291768 ms
Verification P50	1.165550 ms
Verification P95	2.778420 ms

指标	结果
Shared w/o Verification Te2e	7195.834362 ms
Paired Proposed Te2e	7197.126130 ms
Absolute verification overhead	1.291768 ms
VO Mean	0.019201%
VO P50	0.016172%
VO P95	0.050686%

Table I-B. Component-wise paired verification overhead

在 60 条 Proposed 实测行中，component-wise decomposition 的 delta 与实测 Tver 对应 60/60，一致性 gate 全部通过。该分析是 derived component analysis，不是新的独立 wall-clock run。

5.3 Benign Verification Microbenchmark

N	Mean (ms)	P50 (ms)	P95 (ms)	Min (ms)	Max (ms)
30,000	1.211927	1.091100	2.893205	0.239600	11.268800


Table I-C. Benign verification microbenchmark

30,000 次 benign verification 的 Mean=1.211927 ms、P50=1.091100 ms、P95=2.893205 ms。结果表明 verification 处于毫秒级，且尾部仍可能出现数毫秒调度波动，因此论文中不应使用“always sub-millisecond”或“zero overhead”等表述。

5.4 Verification Scalability

Posting-list	Mean (ms)	P50 (ms)	P95 (ms)	Response (bytes)	Response (KiB)
1	0.048420	0.040800	0.084500	3159.5	3.085
5	0.112779	0.101450	0.178315	7091.0	6.925
10	0.182518	0.173600	0.238045	12038.0	11.756
20	0.336496	0.323900	0.419090	21863.0	21.351
40	0.664940	0.635950	0.804030	41678.0	40.701

Table I-D. Verification Scalability



这个图也只是示意，数据没问题但是如果按照数据画图会非常重叠拥挤，不知道怎么呈现会比较美观，可以再试试柱状图等等

随着 posting-list size 从 1 增加到 40，Mean verification latency 从 0.048420 ms 增加到 0.664940 ms，约为 13.73 倍；serialized response size 从 3159.5 bytes 增加到 41678.0 bytes，约为 13.19 倍。数据表现为平稳增长趋势，但本实验没有进行线性拟合检验，因此不应写成“perfectly linear”或“strictly linear”。

5.5 Offline Index Construction Cost (Tidx)

Documents	Warm-up	Formal runs	Mean (s)	P50 (s)	P95 (s)	Min (s)	Max (s)	Std (s)	Mean output
164	1	5	24.299	24.551	25.783	21.957	26.043	1.326	20.47 MiB

Table I-E. Offline index construction cost

Tidx 的正式 scope 为 full offline retrieval preparation：包括冻结输入校验、文本预处理、protected keyword/posting 构建、policy digest、AES-GCM 加密、Merkle metadata、metadata serialization、dense document embedding 预计算及冻结 I prepare path 的本地模型加载；不包括 query-time reranking、verification、rewrite、generation 和 API 工作。

5 次正式构建均成功，Mean=24.298594 s，P50=24.551228 s，P95=25.783229 s，Min=21.957285 s，Max=26.042823 s，Population Std=1.326454 s。Mean output size=21,463,500 bytes（约 20.47 MiB）。本轮 new_api_calls_for_tidx=0、model downloads=0，正式资产均未修改。

6. 结果分析

6.1 系统主要瓶颈

Proposed Framework 的平均 Te2e 为 7197.126 ms。按分量占比计算，Tgen=4865.174 ms，占 67.599%；Tsem=2328.184 ms，占 32.349%；Tret=2.477 ms，占约 0.034%；Tver=1.292 ms，占约 0.018%。因此当前主要瓶颈是远程 answer generation，其次是 query rewriting + semantic reranking；protected retrieval 和 proof verification 只占极小比例。

6.2 Verification 的真实边际成本

如果直接比较两个独立执行的 Proposed 与 w/o Verification，Te2e 相差 80.392 ms，但两个 run 的 API/network、rewrite、reranking、generation 都存在自然波动，且早期 pairing audit 已发现 protected response/candidate count 不完全一致，因此该差值不具有严格的单变量因果解释。

采用 component-wise paired causal decomposition 后，在同一条 Proposed 实测记录中只移除 Tver，得到 verification 平均边际开销 1.291768 ms，VO mean=0.019201%。这与 30,000 次 benign verification microbenchmark 的 1.211927 ms 均值处于同一量级，形成了相互支持的证据。

6.3 Verification 稳定性

Benign microbenchmark 的 P50=1.091100 ms、P95=2.893205 ms。P95 明显高于 P50，说明 Windows 调度、缓存与短时测量噪声会影响尾部延迟，因此采用高重复统计而不是单次测量是必要的。尽管存在尾部波动，verification 在端到端数秒级 LLM pipeline 中仍只贡献极小比例。

6.4 可扩展性分析

Posting-list size 从 1 增长到 40 时，verification mean 与 response bytes 均随规模增加。最大规模下 Mean/P50/P95 分别为 0.664940/0.635950/0.804030 ms，仍保持在 1 ms 左右的量级；response size 则增加至约 40.70 KiB。该结果说明 proof/response 规模增长会带来可测量但当前仍较小的验证开销。由于本实验没有将 posting-list scale 等价为真实 Small/Medium/Large repository，因此不能把这 5 个规模直接改名为知识库规模。

6.5 Offline 与 Online 开销的关系

Tidx≈24.299 s 是离线一次性/更新时的 full retrieval preparation 成本，不属于每个 query 的在线响应。在线 Te2e 仍为约 7.197 s，主要受远程生成和语义增强影响。论文应分别报告 Tidx 与 Te2e，避免把离线预处理与用户请求延迟混合。

7. 论文表格与图像填写建议

7.1 原论文 Table VII 的填写原则

原论文 Table VII 的参考结构为 Setting | Tidx | Tret | Tver | Tsem | Tgen | Te2e | VO，并预留 Small/Medium/Large repository 三行。当前正式实验只对“164 篇当前知识库”完成了完整 Tidx 与在线 latency decomposition；另有 posting-list 1/5/10/20/40 的 verification scalability，但它不能等价替代 Small/Medium/Large repository。

说明：因此不要把 posting-list size 1/5/10/20/40 强行映射成 Small/Medium/Large repository。若最终论文允许根据导师最新要求调整表格结构，建议使用“Current repository (164 docs)”作为主表一行，并把 posting-list scalability 独立成表/图。

Setting	Tidx (ms)	Tret (ms)	Tver (ms)	Tsem (ms)	Tgen (ms)	Te2e (ms)	VO
Current repository (164 docs)	24,298.594	2.477	1.292	2,328.184	4,865.174	7,197.126	0.0192%

建议主表填写：Current-repository overhead (Proposed Framework)

注意：这里的 Tidx 使用 ms 与其他列统一。如果论文允许混合单位，也可在 caption 或注释中写 Tidx=24.299 s。VO 建议使用严格 paired analysis 的约 0.0192%，并在正文说明 observed independent-run difference 不能作为 verification causal overhead。

7.2 建议补充的 Verification Microbenchmark 表

根据您在群里所说“benign verification 重复测量并报告 P50/P95”，可以在 Table VII 后或 supplementary material 中增加 Table I-C，报告 N=30,000、Mean=1.212 ms、P50=1.091 ms、P95=2.893 ms、Min=0.240 ms、Max=11.269 ms。

7.3 建议的 Scalability 表与 Fig. 4

原论文 Fig. 4 位置使用 Fig. 4(a)/(b)。

- Fig. 4(a): Verification Latency vs Posting-list Size；绘制 Mean/P50/P95。
- Fig. 4(b): Serialized Response Size vs Posting-list Size；单位可用 KiB。

7.4 Independent 与 Paired 结果如何在论文中同时出现

主表中的 Tret/Tver/Tsem/Tgen/Te2e 可保留 observed independent end-to-end measurements，因为它们反映真实用户请求路径；verification 的边际开销则使用 component-wise paired causal analysis 单独说明。不要用 80.392 ms 作为 verification cost。

8. 可直接写入论文的补充说明

8.1 System Overhead and Scalability (中文版)

在系统开销实验中，我们将在线端到端延迟分解为受保护检索（Tret）、证明验证（Tver）、语义增强（Tsem）和答案生成（Tgen），并将离线索引构建成本 Tidx 单独统计。对于完整框架，Tret、Tver、Tsem 和 Tgen 的平均延迟分别为 2.477 ms、1.292 ms、2328.184 ms 和 4865.174 ms，对应平均在线端到端延迟 7197.126 ms。生成阶段占总延迟的 67.599%，语义增强占 32.349%，说明主要计算开销来自远程答案生成和语义处理，而非 proof verification。

由于 Proposed Framework 与 w/o Verification 的独立端到端运行包含正常的 API、网络、查询改写、重排和生成波动，我们不将二者约 80.392 ms 的原始 Te2e 差值解释为验证的因果开销。进一步地，我们基于同一条冻结 Proposed 分阶段实测记录进行 component-wise paired causal decomposition，仅移除其中实测的 Tver。60 个配对单元均通过一致性检查，得到 verification 平均边际开销 1.292 ms，平均 VO 为 0.0192%。

为了稳定测量短时验证开销，我们对 benign proof verification 进行了 30,000 次重复测量。平均延迟为 1.212 ms，中位数为 1.091 ms，P95 为 2.893 ms。该结果表明验证处于毫秒级，并不支持“始终亚毫秒”的表述。

在可扩展性实验中，我们将 posting-list size 从 1 增加到 5、10、20 和 40，并同时记录 verification latency 与 serialized response size。Mean verification latency 从 0.048 ms 增长到 0.665 ms，response size 从 3159.5 bytes 增长到 41678 bytes。两项指标均随 posting-list size 平稳增加；在当前测试范围内，proof verification 仍未成为主要在线瓶颈。

离线索引构建在独立临时目录中完成，不修改正式索引、冻结数据或既有实验结果。对 164 篇文档进行 full offline retrieval preparation 时，5 次正式构建的平均 Tidx 为 24.299 s，P50 为 24.551 s，P95 为 25.783 s。Tidx 作为离线预处理成本单独报告，不计入在线端到端延迟。

We decomposed the online end-to-end latency into protected retrieval (Tret), proof verification (Tver), semantic enhancement (Tsem), and answer generation (Tgen), while reporting the offline index-construction cost (Tidx) separately. For the Proposed Framework, the mean Tret, Tver, Tsem, and Tgen were 2.477 ms, 1.292 ms, 2328.184 ms, and 4865.174 ms, respectively, resulting in a mean online end-to-end latency of 7197.126 ms. Answer generation accounted for 67.599% of the measured latency and semantic enhancement for 32.349%, indicating that the dominant overhead came from remote generation and semantic processing rather than proof verification.

Because the independently executed Proposed and w/o Verification runs include normal variability from the remote API, networking, query rewriting, reranking, and answer generation, we did not interpret their raw end-to-end difference of approximately 80.392 ms as the causal verification overhead. Instead, we performed a component-wise paired causal decomposition on the same frozen Proposed measurement, removing only its measured Tver component. All 60 paired units passed the arithmetic and source-consistency checks. The resulting mean marginal verification overhead was 1.292 ms, with a mean verification-overhead fraction of 0.0192%.

To obtain stable estimates for the short verification path, we additionally performed 30,000 benign proof-verification measurements. The mean latency was 1.212 ms, the median was 1.091 ms, and the P95 was 2.893 ms. These measurements support a millisecond-scale characterization rather than an “always sub-millisecond” claim.

For scalability, we increased the posting-list size from 1 to 5, 10, 20, and 40 while measuring both verification latency and serialized response size. The mean verification latency increased from 0.048 ms to 0.665 ms, while the response size increased from 3159.5 bytes to 41678 bytes. Both quantities increased smoothly over the evaluated range, and proof verification did not become the dominant online bottleneck.

Offline index construction was benchmarked in an isolated temporary directory without modifying the frozen repository, formal indexes, or previously validated Experiment I measurements. For the 164-document repository, five formal builds of the full offline retrieval-preparation path yielded a mean Tidx of 24.299 s, a P50 of 24.551 s, and a P95 of 25.783 s. Tidx is reported separately as an offline preprocessing cost and is not included in the online end-to-end latency, which remains defined as $T_{ret} + T_{ver} + T_{sem} + T_{gen}$.

8.2 论文表格/图注建议

- 表：系统开销分解。Tidx 为离线索引准备时间； $Te2e = T_{ret} + T_{ver} + T_{sem} + T_{gen}$ 。
- 表：Benign proof verification 微基准。报告 30,000 次重复测量的 Mean、P50、P95、Min 和 Max。
- 图：不同 posting-list size 下的 verification latency (Mean/P50/P95)。
- 图：不同 posting-list size 下的 serialized response size。