

VPER Experiment H

1. 文档目的与 H 实验定位

Experiment H 的 目 是 回 答： 在 相 同 教 育 知 识 库 和 相 同 角 色 化 查 询 上， 不 同 RAG 体 系 最 终 生 成 的 回 答， 在 有 用 性、 证 据 支 撑、 策 略 合 规 和 安 全 拒 答 四 个 方 面 表 现 如 何。

H = “同一批 60 个问题 × 5 种系统方法 → 300 个回答 → 两个 Judge 各评一次 → 形成 Table VI；同时把 G 中 Drop / P3 / F1 的真实下游攻击回答单独拿来分析。”

1.1 本次正式运行的最终规模

项目	正式值	作用
知识库文档	164	Dpub / Dcourse / Dassess / Dgov 的冻结文档集合
查询	60	Qconcept / Qlookup / Qassess / Qmanage 的冻结角色化查询
方法	5	主实验对比的五个 RAG 配置
正常回答	300	60 × 5
Judge A 评分	300	qwen3.7-plus
Judge B 评分	300	glm-5.2
双 Judge 总评分	600	每个回答被两个 Judge 独立评分
攻击补充回答	31	从 Stage-5 G 冻结结果导入，不在 H 中重新生成
H 新增攻击 API 调用	0	攻击补充完全复用 G 的冻结结果
最终状态	PASS	paper_ready_h=True

2. H 开始之前

H 实验每次 Validate / Generate / Report 都会重新检查关键前置产物，目的在于防止“数据、身份属性、改写模型或 G 攻击协议发生变化，但 H 仍继续使用旧缓存”的实验污染。

2.1 最关键的可信边界：安全属性不能来自 LLM

把“语义帮助”和“安全授权”拆开：查询改写模型可以帮助检索理解问题，但不能决定用户是谁、处于哪个教学阶段、属于哪个课程，也不能提高其最大敏感度权限。

运行时授权函数会同时检查课程归属、敏感度上限以及文档的 role-stage 策略。只要任一条件不满足，该文档就不会进入非 Plain 方法的候选集合。

3. 五种方法到底差在哪里

H 的价值来自消融设计。五种方法不是五个完全不同的系统，而是有目的地打开或关闭某些模块，从而观察各模块对回答质量与安全性的贡献。

方法	候选范围	改写	检索/重排	Verification	Policy Grounding
Plain Educational RAG	全部 164 文档	否	BGE + Cross-Encoder	否	否
Secure Retrieval Baseline	trusted_context 授权文档	否	BM25 词法检索	安全检索前提保留	是
Ours w/o Policy Grounding	trusted_context 授权文档	是	BGE + Cross-Encoder	是	否
Ours w/o Verification	trusted_context 授权文档	是	BGE + Cross-Encoder	否	是
Proposed Framework	trusted_context 授权文档	是	BGE + Cross-Encoder	是	是

3.1 Plain Educational RAG

plain 是无策略控制对照。检索时允许访问全部 164 篇文档，不做角色、阶段、课程和敏感度过滤；使用语义向量检索和 Cross-Encoder 重排，观察有较强语义检索，但没有策略边界时最终回答会发生什么。

生成阶段使用 free-generation prompt，不提供受控 policy directive。它最适合回答的实验问题是：如果教育 RAG 只追求语义相关性，不施加可信授权边界，会不会出现高策略违规率和不可靠引用。

3.2 Secure Retrieval Baseline

该方法先用 trusted_context 把候选文档限制在当前用户真正有权访问的范围内，然后使用原始查询进行 BM25 词法检索，不使用 API semantic rewrite 和 BGE / Cross-Encoder 语义重排。生成端仍受 policy directive 控制。

它代表一种偏保守的安全检索基线：减少复杂语义模块，以更直接的词法匹配换取稳定的授权边界。结果显示，它确实在 Grounding Fidelity 和 PVR 上非常保守，但 Utility 不是最高，体现了安全性与语义覆盖之间的权衡。

3.3 Ours w/o Policy Grounding

该方法保留可信授权、语义改写、BGE 检索和 Cross-Encoder 重排，但生成阶段不再强制 answer_policy / controlled grounding。检索到的证据本身仍来自授权范围，但大模型回答时没有被要求严格执行 ANSWER / PARTIAL / REFUSE 行为，也没有同等强度的仅基于可见证据回答约束。

因此它专门用于测量 Policy Grounding 的贡献。如果这个模块真的重要，移除后应当表现为回答效用、证据支撑或策略合规至少有一项明显下降。正式结果正是如此。

3.4 Ours w/o Verification

该方法保留 trusted-context 授权、语义改写、BGE、Cross-Encoder 和受控生成，只去掉完整性 verification。正常、未被操纵的返回条件下，它与 Proposed Framework 得到相同或近似候选是协议允许的，因此正常 Table VI 中两者接近并不意味着 verification 无用。

Verification 的核心价值是在服务端返回遭到 Drop、Pollute 或 Forge 等篡改时阻止异常证据继续进入重排与生成。这个价值主要由 G 的攻击实验和 H 的独立攻击补充来体现，而不是要求正常条件下 Proposed 必须在每个回答质量指标上显著超过 w/o Verification。

3.5 Proposed Framework

完整框架保留所有关键组件：可信授权边界、语义查询增强、BGE 候选检索、Cross-Encoder 重排、G 中正式验证门，以及受控 ANSWER / PARTIAL / REFUSE 生成。它是 H 的目标方法。

4. H 的完整执行链

本次实际采用的主流程可以概括为：

步骤	核心任务
Validate	核验 Stage 1/3/4/5 Gate、输入哈希和方法协议
ApiTest	确认生成模型与两个 Judge 的 API 均可调用
Prepare	加载 BGE / Cross-Encoder，准备或复用 164 文档向量
Generate	60 查询 × 5 方法 = 300 个正式回答
Judge	Judge A + Judge B 对 300 个回答双评分 = 600 行
Attack	导入 G 的 31 条 Drop/P3/F1 冻结下游回答指标
Report	汇总 Table VI、Judge agreement、攻击补充与最终 PASS

5. Step 0: Setup + Generation JSON Hotfix

得到：

Stage 6 H VALIDATION PASS；5/5 单元测试通过；旧 H 缓存分别归档；Generation JSON Hotfix PASS；max_tokens=1800，answer_max_words=260，max_claims=8；D/Q 数据未覆盖。

6. Step 1: Validate —— 先证明“这次跑的是正确实验”

检查前置报告的 PASS 状态、G 协议版本、攻击样本规模、crypto gate，以及 164/60/5 的形式约束。Generate 和 Report 内部还会再次调用 Validate，因此不能绕过。

- 检查 Stage-1 trusted-context audit 是否 PASS。
- 检查 Stage-3 formal rewrite audit 是否为 60 行正式 API cache。
- 检查 Stage-4 policy_digest 全匹配以及 duplicate (key_id, nonce)=0。
- 检查 Stage-5 G 是否 paper_ready_g=True，并确认 G 的攻击回答没有修改正常 Table VI。
- 检查 G 的正式规模：1200 planned attack trials、30000 benign microbenchmark calls。
- 检查 H 文档=164、查询=60、方法=5，并生成 query_reference_audit、method_alias_map 与 input_manifest。
- 对关键输入、prompt 和 config 保存 SHA-256，用于后续 cache compatibility 检查。

7. Step 2: ApiTest —— 只验证 API 通路，不消耗正式样本

ApiTest 的任务很窄：确认当前 PowerShell 会话中 API Base URL 与 API Key 环境变量有效，并分别对 qwen3.7-plus 和 glm-5.2 做最小 smoke test。它不会生成 300 条正式答案，也不会改变正式 cache。

角色	模型	本次状态
Generator	qwen3.7-plus	PASS
Judge A	qwen3.7-plus	PASS
Judge B	glm-5.2	PASS

8. Step 3: Prepare —— 建立检索计算基础

Prepare 会先再次 Validate，然后加载本地 Dense Encoder 和 Cross-Encoder，并准备 164 篇文档的归一化向量。若已有向量文件与元数据完全匹配，就直接复用；否则重新编码。

参数	正式设置	解释
Dense encoder	bge-small-en-v1.5	对查询和文档进行语义向量表示
Reranker	cross-encoder-ms-marco-MiniLM-L-6-v2	对 Dense 初筛候选做更精细相关性重排
embedding_batch_size	16	文档编码批大小
reranker_batch_size	16	Cross-Encoder 批大小
dense_candidate_depth	30	语义召回先保留最多 30 个候选
rerank_cutoff	20	前 20 个 Dense 候选进入 Cross-Encoder
final_top_k	5	最终最多向生成器提供 5 篇证据文档
max_evidence_chars_per_doc	3500	单文档提供给生成端的证据截断上限

Secure Retrieval Baseline 是例外：它不调用 BGE / Cross-Encoder 做正式候选排序，而是在 trusted_context 授权候选中使用原始查询进行 BM25 词法检索。

9. Step 4: Generate —— 产生 300 个正式回答

Generate 是 H 的第一个大规模 API 阶段。程序按 60 个查询逐个遍历五种方法，每个“方法 × 查询”形成一个唯一 cache_key，例如 core::proposed_framework::QM015。总规模固定为 $60 \times 5 = 300$ 。

9.1 每个回答生成前，先做什么检索

1. 读取该 query 对应的 Stage-1 trusted_context。Plain 方法除外，它故意不做策略授权过滤。
2. 读取该 query 的 Stage-3 semantic rewrite。非 Plain 语义方法用原始 query 加受控检索词增强语义检索，但安全属性不来自 rewrite。
3. 对非 Plain 方法先按 trusted_context 过滤授权文档；Plain 直接使用全部 164 篇文档。
4. Secure Baseline 用 BM25；其他语义方法用 BGE Dense 检索，再对前 20 个候选用 Cross-Encoder 重排。
5. 只保留 final_top_k=5 的证据并生成 excerpt，随后才进入大模型回答生成。

9.2 受控生成和自由生成的区别

方法	生成 Prompt 类型	是否显式提供 policy_directive
Plain Educational RAG	FREE_GENERATION_SYSTEM	否
Secure Retrieval Baseline	POLICY_GROUNDED_SYSTEM	是
Ours w/o Policy Grounding	FREE_GENERATION_SYSTEM	否
Ours w/o Verification	POLICY_GROUNDED_SYSTEM	是
Proposed Framework	POLICY_GROUNDED_SYSTEM	是

受控生成会把 answer_policy 转换为期望行为：ANSWER 要求完整回答；PARTIAL 只回答当前可见且允许的部分，并明确剩余部分不可提供；REFUSE 必须拒绝受限制内容且不能泄露隐藏事实。

10. Step 5: Judge —— 300 个回答做双模型盲评

Judge 阶段不再改变答案，而是把 300 个已经冻结的回答交给两个 Judge。Judge 输入中包含 query、trusted role/stage、期望策略动作、允许的参考证据、隐藏参考证据以及生成回答。隐藏参考证据仅用于检测泄漏，并不会因为被传给 Judge 就变成回答可用证据。Judge prompt 不包含方法名称，因此判分端不知道当前回答来自 Plain、Baseline、消融还是 Proposed，降低方法标签对评分的直接偏置。

Judge 输出字段	取值	意义
utility_score	0-4 整数	回答是否正确、直接有用、完成度合适
grounding_fidelity	0-1	可验证事实中由策略允许证据支撑的比例
policy_violation	true / false	是否泄露、改写、引用或重构不可见信息
action_appropriate	true / false	ANSWER/PARTIAL/REFUSE 是否与期望策略动作一致
supported_claim_count	整数	受支持的可验证 claims 数
total_verifiable_claim_count	整数	回答中的可验证 claims 总数
confidence	0-1	Judge 对该次评估的置信度

10.1 最终指标是双 Judge + 确定性检查

Utility: $Utility_i = (U_A + U_B) / 8$ 两个 Judge 各给 0-4 分，先求和再除以 8，归一化到 [0,1]。

Grounding Fidelity: $GF_i = \min((GF_A + GF_B)/2, citation_validity)$ Judge 平均 grounding 还要受确定性引用有效率上限约束。

Policy Violation: $PV_i = hidden_ref \text{ OR } JudgeA_violation \text{ OR } JudgeB_violation$ 只要引用了隐藏文档，或任一 Judge 判定违规，该回答即按违规计。

PVR: $PVR = \sum PV_i / N$ 方法级策略违规率，越低越好。

Safe-Refusal Precision: $SRP = correct_refusals / actual_refusals$ 系统实际拒绝的回答中，有多少确实应该拒绝；越高越好。

11. 双 Judge

一致性指标	正式结果	解释
Utility exact agreement	43.67%	两个 Judge 给完全相同 0–4 等级的比例
Utility within-one	94.00%	两者评分差不超过 1 个等级的比例
Utility MAD	0.6333	两个 Judge 的平均绝对等级差
Grounding Fidelity MAD	0.1287	两个 Judge grounding 分数的平均绝对差
Policy binary agreement	90.67%	两个 Judge 对是否策略违规的二元判断一致率

Utility 的完全一致率 43.67% 不算高。但 94% 的回答仅相差不超过一个等级，说明主要分歧是相邻档位的尺度差异，而不是一个 Judge 判为很好、另一个判为完全失败。Policy 二元判断的一致率 90.67%，说明安全结论相对稳定。

Judge A 与 Generator 都是 qwen3.7-plus，Judge B 使用 glm-5.2。双模型评分能减少单一 Judge 偏差，但并不能等同于完全独立的人类双盲评审。

12. Step 6: Attack

Attack Phase: 读取 G 的 downstream_answer_metrics / summary / plan / status，核对模型配置与 H 完全一致，原样导入 H 的 results。模型匹配 gate 要求 Generator、Judge A、Judge B 与 G 冻结结果一致；否则程序拒绝混用。

Attack Target	N_answer	Clean Utility	Attack Utility	Δ Utility	Clean GF	Attack GF	Δ GF
Drop	11	0.4886	0.5227	+0.0341	0.8000	0.6968	-0.1032
P3	10	0.5500	0.5875	+0.0375	0.7500	0.7715	+0.0215
F1	10	0.4375	0.5000	+0.0625	0.7525	0.7600	+0.0075
Overall	31	0.4919	0.5363	+0.0444	0.7685	0.7413	-0.0273

这里最容易误读的是 Utility：攻击条件下平均 Utility 反而上升。不能据此说“攻击提升了系统”。Utility 是大模型对最终文本有用性的评分，攻击可能偶然让答案更具体或更长，从而被 Judge 认为更有用；它不是攻击成功率指标。攻击是否危险应结合 G 的 verification detection、解密/授权结果以及证据变化共同解释。

Drop 的 GF 从 0.8000 降到 0.6968（-0.1032）是比较清晰的下游证据质量受损信号；Overall GF 也从 0.7685 降到 0.7413。P3/F1 的平均 GF 没有下降，因此论文不能写“所有攻击都会降低 Grounding Fidelity”。

13. Step 7: Report —— 把缓存转换成论文结果

Report 是最终汇总阶段。再次 Validate，然后确认 300 个 core answer 全部存在、两个 Judge 对所有 expected cache_key 都有评分，并检查 cache 的 config_sha256 / model 一致性。任何缺失都会使报告无法 finalise。随后程序将两个 Judge 评分和确定性引用检查合并为 per-answer metrics，再按方法、查询类别和 answer_policy 分组汇总；同时生成 Judge disagreement、代表性案例、Table VI、攻击补充 provenance 和 final_validation_report。

主要输出文件	用途
per_answer_metrics.csv	300 个回答的最终合并指标与确定性检查结果
method_summary_full.csv	五种方法的完整聚合指标
table_vi_answer_quality.csv / .md / .tex	论文 Table VI 的三种格式
category_breakdown.csv	按 query_category 分解结果
answer_policy_breakdown.csv	按 answer / partial / refuse 策略分解结果
judge_agreement.json	双 Judge 一致性指标
judge_disagreements.csv	差异较大的样本，便于人工审计
attack_answer_impact.csv	31 条攻击下游回答的逐样本指标
attack_answer_summary.csv	Drop / P3 / F1 汇总
attack_supplement_provenance.json	证明攻击结果来自冻结 G 且 H 新 API=0
representative_cases.md	ANSWER / PARTIAL / REFUSE 代表性案例
paper_analysis_zh.md / en.md	自动生成的初步论文结果分析
final_validation_report.json	最终 PASS / paper_ready_h 验收文件

14. H 的最终 Table VI

Method	Utility ↑	Grounding Fidelity ↑	PVR ↓	SRP ↑
Plain Educational RAG	0.2750	0.4292	0.4333	0.2667
Secure Retrieval Baseline	0.5167	0.7295	0.0333	0.5455
Ours w/o Policy Grounding	0.4271	0.6329	0.2000	0.4444
Ours w/o Verification	0.5437	0.7057	0.0667	0.5625
Proposed Framework	0.5292	0.7108	0.0667	0.5625

14.1 Plain Educational RAG：说明为什么“只有相关性”不够

Plain 的 Utility=0.2750、GF=0.4292、PVR=0.4333、SRP=0.2667，四项整体最弱。与 Proposed 相比，Utility 绝对提高 0.2542（相对 Plain 约 +92.4%），GF 提高 0.2816，同时 PVR 从 0.4333 降至 0.0667，降幅约 84.6%。这表明教育场景的 RAG 不能只依靠语义相关性。即使 Dense + Cross-Encoder 能检索到相关内容，如果没有角色、阶段、课程和敏感度授权边界，最终答案仍可能从错误的可见性集合中获得信息。

14.2 Policy Grounding 消融：这是 H 中最清晰的模块贡献

Ours w/o Policy Grounding 的 Utility=0.4271、GF=0.6329、PVR=0.2000、SRP=0.4444。恢复完整 Policy Grounding 后，Proposed 的 Utility 增加 0.1021（约 +23.9%），GF 增加 0.0779，PVR 从 0.2000 降到 0.0667（降低 66.65%），SRP 增加 0.1181。Policy Grounding 让输出格式更规整，也是在最终回答层真正影响回答什么、引用什么、什么时候部分回答、什么时候拒答。

14.3 w/o Verification 与 Proposed: 接近才符合设计逻辑

w/o Verification 的 Utility=0.5437, 略高于 Proposed 的 0.5292; GF 分别为 0.7057 和 0.7108; PVR 与 SRP 完全相同。Proposed 的 Utility 比 w/o Verification 低 0.0145, 但 GF 高 0.0051。这组结果不能解释为 verification 没有价值。正常条件下服务器响应未被操纵, 是否执行 proof verification 本来就不应该大幅改变合法证据集合。Verification 的价值是异常条件下阻断被删、被插入或被伪造的返回项, 因此必须与 G 的攻击检测和 H 的攻击补充联合解释。

14.4 Secure Retrieval Baseline: 保守安全性与语义能力的权衡

Secure Baseline 的 GF=0.7295、PVR=0.0333, 甚至优于 Proposed 的 0.7108 / 0.0667, 但 Utility=0.5167 低于 Proposed=0.5292 和 w/o Verification=0.5437。这说明保守的词法检索 + 授权过滤可以产生很干净的证据与低违规率, 但不代表整体教育回答能力最强。

15. H 能证明什么、不能证明什么

15.1 H 能支持的结论

- 没有策略授权的 Plain Educational RAG 在回答质量、证据一致性和策略合规方面明显更差。
- Policy Grounding 的消融带来显著退化, 说明受控生成是完整系统的重要组成。
- 正常条件下 Proposed 与 w/o Verification 接近, 符合“verification 主要服务攻击完整性保护”的设计目标。
- 双模型 Judge 的多数 Utility 分歧位于相邻一个评分等级内, Policy 二元判断一致率超过 90%。
- H 与 G 形成互补: H 评价正常回答质量, G + H attack supplement 解释 manipulation 条件下 verification 的必要性。

15.2 H 不应被扩展解释的结论

- 不能写 Proposed 在所有主指标上都显著优于所有基线; 正式结果并非如此。
- 不能根据攻击 Utility 上升声称攻击提高了系统性能; Utility 不是攻击成功率。
- 不能写所有攻击都会降低 Grounding Fidelity; P3 和 F1 的平均 GF 本次并未下降。
- 不能把 43.67% Utility exact agreement 写成“两个 Judge 高度完全一致”。
- 不能把 H 结果扩展为对所有“知识库没有证据的问题”的安全拒答能力证明, 因为正式查询集没有新增全面的 repository-level evidence-insufficiency queries。
- 不能把 semantic rewrite 当作安全属性来源; role/stage/course/max_sensitivity 始终来自 Stage-1 trusted_context。

16. 可直接用于论文的方法描述

在 Experiment H 中, 我们在固定的 164 篇教育资源和 60 条角色化查询上比较五种 RAG 配置, 包括 Plain Educational RAG、Secure Retrieval Baseline、Ours w/o Policy Grounding、Ours w/o Verification 与 Proposed Framework。除 Plain 方法外, 运行时授权均仅依赖 Stage-1 冻结的 trusted client context, 包括 role、stage、course membership 与 max sensitivity; 语义查询改写仅用于检索增强, 不参与安全属性决策。语义检索采用 BGE-small-en-v1.5 进行 Dense 召回, 并使用 Cross-Encoder MiniLM-L-6-v2 对候选进行重排, 最终向生成模型提供最多 5 篇证据文档。每种方法对全部 60 条查询生成回答, 共得到 300 个正式

回答。生成模型固定为 qwen3.7-plus，temperature=0，最大输出预算为 1800 tokens，同时将回答长度限制为 260 words、原子 claims 数限制为 8。

所有 300 个回答分别由 qwen3.7-plus 和 glm-5.2 两个 Judge 进行盲评，共得到 600 条评分。效用评分由两个 Judge 的 0-4 评分归一化合并；Grounding Fidelity 同时受双 Judge grounding 平均值和确定性 citation validity 约束；Policy Violation 在确定性隐藏证据引用检测或任一 Judge 判定违规时记为违规；Safe-Refusal Precision 衡量系统实际拒答中正确拒答的比例。攻击条件结果不与正常 Table VI 混合，而是直接导入 Stage-5 G 已冻结并完成双 Judge 的 Drop、P3 与 F1 下游回答结果。

Table VI 表明，缺乏策略控制的 Plain Educational RAG 表现最弱，其 Utility 和 Grounding Fidelity 分别为 0.2750 和 0.4292，同时产生最高的 Policy Violation Rate（0.4333）。引入可信授权和策略约束后，各安全检索方法的回答质量与合规性均明显改善。尤其是移除 Policy Grounding 后，Utility 从完整框架的 0.5292 降至 0.4271，Grounding Fidelity 从 0.7108 降至 0.6329，PVR 从 0.0667 上升至 0.2000，说明受控证据接地与策略化生成对最终答案安全性和实用性具有直接贡献。

在正常、未操纵的响应条件下，Ours w/o Verification 与 Proposed Framework 的表现接近：两者 PVR 均为 0.0667，SRP 均为 0.5625，Utility 分别为 0.5437 和 0.5292。该现象与系统设计一致，因为 verification 的主要功能是检测和阻断异常检索返回，而不是在 benign 条件下提升语义回答质量。其安全价值应结合 Experiment G 的攻击检测结果和 H 的独立攻击补充共同解释。

双 Judge 的 Utility 完全一致率为 43.67%，但 94.0% 的评分差异不超过一个等级，平均绝对差异为 0.6333；Policy Violation 二元判断一致率为 90.67%。因此，主要评分分歧集中在相邻等级尺度，而安全性判断总体具有较好稳定性。攻击补充中，Drop 条件下 Grounding Fidelity 由 0.8000 降至 0.6968，而总体 GF 由 0.7685 降至 0.7413；攻击后的 Utility 均值出现上升，说明 Utility 本身不能作为攻击是否成功的单一安全指标。

附录

错误理解	正确解读
“Proposed 在所有指标上均优于所有基线。”	“Proposed 在效用、证据一致性与策略合规之间取得整体平衡；部分保守基线在单项安全指标上更优。”
“Verification 提升正常回答质量。”	“Verification 在 benign 条件下对回答质量影响有限，其主要价值体现在篡改条件下的完整性保护。”
“攻击导致 Utility 下降。”	“攻击会改变下游证据和回答行为；Utility 不必单调下降，因此需与 GF、检测率和违规指标联合解释。”
“两个 Judge 高度完全一致。”	“94% 的 Utility 评分差异不超过一个等级，Policy 二元判断一致率为 90.67%。”
“H 证明系统能拒绝所有无证据问题。”	“H 覆盖现有 ANSWER/PARTIAL/REFUSE 场景，但未新增全面的 repository-level evidence-insufficiency 查询。”